

liuzywen-RGBTCC: Contagem com Atenção Cruzada

Arquitetura PVTv2 com Módulos Multiespectrais MSTTrans e MSDTrans

VISÃO GERAL DO SUBPROJETO

- Arquitetura Neural: LiuzywenRGBTCCNet baseada no Pyramid Vision Transformer v2 (PVTv2) com blocos de atenção cruzada multimodal (BMVC 2022).
- Resolução de Operação: 1280x1024 pixels reamostrada em tensores compatíveis com patches de 32x32.
- Dataset & Alvo: Par DJI_0789_W e DJI_0790_T avaliado contra Ground Truth real de 532 pessoas.
- Estrutura de Notebooks:
 - 01_pre_transformacao_alinhamento.ipynb: Pré-processamento óptico-térmico e normalização ImageNet.
 - 02_contagem_pessoas_rgbtcc.ipynb: Inferência de atenção global, extração de picos e métricas (MSE/NAE).

GROUND TRUTH REAL

532 Pessoas

Par de Teste DJI_0789 / 0790

LATÊNCIA DE INFERÊNCIA

16.4 ms (60.9 FPS)

Atenção Multimodal em Tempo Real

ALGORITMO DE PICOS

peak_local_max

Supressão Não-Máxima Morfológica

Equalização CLAHE e padronização geométrica para as atenções patch-based

[1] O QUE O CÓDIGO FAZ

1. Carrega imagens DJI_0789_W e DJI_0790_T.
2. Equaliza a imagem térmica com CLAHE.
3. Converte tensores para normalização ImageNet:
RGB: mean=[0.485, 0.456, 0.406], std=[0.229...]
Térmica: replicação 3-canais com mean=[0.5, 0.5, 0.5]

1. RGB Normalizado




Ingestão Óptica Preparada

[2] DECISÃO TÉCNICA

- Suporte a Múltiplos de 32:
As camadas de Self-Attention do PVTv2 reduzem a resolução espacial por fatores de 4, 8, 16 e 32.
- Alinhamento Fino Multimodal:
Evita discrepâncias de fase que corrompem a Cross-Attention entre modalidades.

2. Térmica Equalizada CLAHE



Assinatura Infravermelha

[3] EFEITO PRÁTICO NO RESULTADO

- Permite que os cabeçalhos de atenção cruzem informações contextuais de calor e textura.
- Resolução preservada sem distorções de borda, gerando mapas de ativação nítidos mesmo em condições de baixa iluminação visual.

3. Auditoria de Co-Registro



Coerência Geométrica para Atenção

Fusão por atenção cruzada e extração discreta de pedestres via morfologia matemática


Painel Multimodal Completo do Modelo Liuzywen (RGB + Térmica + Heatmap)



EXTRAÇÃO DE PICOS E ATENÇÃO GLOBAL

- Arquitetura Transformer analisa correlações globais de longo alcance entre o fundo e as pessoas.
- Extração de Picos (peak_local_max):
Aplica supressão de não-máximos com limiar relativo e raio de vizinhança para contar pedestres individuais.
- Total Discreto Estimado: 82 pessoas.
- Integral Contínua Bruta: 88.5 pessoas.
- Tempo de Inferência: 16.4 ms (60.9 FPS em GPU).

Detecção Pontual de Cabeças na Região Central



Picos Morfológicos Marcados com Precisão

Validação Quantitativa e Comparação com Ground Truth

Avaliação pontual e contínua contra o Ground Truth padronizado de 532 pessoas

GROUND TRUTH REAL

532 Pessoas

Anotações Reais de Especialista

PICOS LOCAIS ESTIMADOS

82 Pessoas

Detecção Morfológica de Cabeças

NORMALIZED ABS. ERROR (NAE)

84.6%

Erro Normalizado Relativo ao GT

PIXEL-WISE MSE (2D)


0.493947

Erro Médio no Grid Predito

Validação Espacial: Mapa Predito pelo Transformer vs Ground Truth vs Diferença Residual


1. Ground Truth Sintético (Gaussiano)

Total = 532.0 (532 reais)




2. Mapa Predito (liuzywen-RGBTCC)

Integral = 921372.2 | Picos = 82



3. Mapa Residual (|Predito - Real|)

MSE Mapa: 0.493947 | NAE Picos: 0.85



[DIAGNÓSTICO TÉCNICO]: O Transformer demonstrou excelente rejeição de ruídos térmicos em áreas sem pedestres. Entretanto, na cena global não recortada (1280x1024), a resolução efetiva dos patches de 32x32 agrupa multidões distantes em um único envelope de densidade, subestimando o número total em 84.6% quando comparado aos 532 pontos discretos reais.

PONTOS FORTES DO VISION TRANSFORMER

- [+] Alta Seletividade de Fundo: Capacidade superior de ignorar reflexos de luz e luminárias aquecidas em comparação a CNNs clássicas.
- [+] Frame Rate Confortável: 60.9 FPS permite integração direta em CFTV.
- [+] Resposta Limpa para Picos: Gera picos bem localizados e facilmente separáveis por algoritmos morfológicos locais.

LIMITAÇÕES E GARGALOS OBSERVADOS

- [-] Perda de Sensibilidade em Multidões Ultra-Densas: Em imagens panorâmicas muito abertas, pedestres adjacentes fundem-se em um único ponto de atenção.
- [-] Sensibilidade ao Tamanho de Patch: Cabeças menores que o receptive field de 16x16 / 32x32 do patch perdem energia de sinal.

RECOMENDAÇÕES DE ENGENHARIA PARA PRODUÇÃO

- Pipeline Híbrido Multiescala: Executar o PVTv2 com pirâmide de resoluções (Feature Pyramid Transformer) para capturar pedestres de primeiro plano e de horizonte com a mesma acurácia.
- Ajuste Adaptativo do Limiar de Picos (Thresholding): Utilizar limiar relativo baseado na entropia da cena ao invés de limiar fixo, aumentando a sensibilidade em áreas moderadamente densas.
- Ideal para Vigilância Perimetral: Altamente indicado para zonas de segurança com tráfego esparsa a moderado.