

Avaliação Comparativa de Modelos Multimodais RGBT

Análise Cruzada entre Dual-Stream CNN vs Vision Transformer em Cena Completa e Recortes

ESCOPO DO ESTUDO COMPARATIVO

- Objetivo: Comparar sistematicamente as duas maiores famílias de redes neurais para contagem multimodal de multidões em imagens óptico-térmicas (RGBT) sob duas condições operacionais:
 1. DEF-RGBTCC (Cena Completa 1280x1024): Dual-Stream CNN VGG-19 + AFM.
 2. liuzywen-RGBTCC (Cena Completa 1280x1024): Pyramid Vision Transformer (PVTv2) + Atenção Cruzada.
 3. DEF-RGBTCC-small (Recortes 448x448): Regime esparso de poucas pessoas com CNN.
 4. liuzywen-RGBTCC-small (Recortes 448x448): Regime esparso de poucas pessoas com Transformer.
- Ground Truth de Teste: Par DJI_0789_W e DJI_0790_T com 532 pessoas reais auditadas.

DATASET DE TESTE

RGBT-CC Oficial

Pares DJI_0789_W & DJI_0790_T

MODELOS COMPARADOS

4 Pipelines

2 CNNs + 2 Vision Transformers

MÉTRICAS CENTRAIS

MSE & NAE

Avaliação Espacial e Quantitativa

Impacto das estratégias de homogeneização dimensional e calibração óptica-térmica

PIPELINE 01: CENA COMPLETA (1280x1024)

- Homografia Global 3x3: Corrige distorção intrínseca e rotação relativa da câmera térmica (FOV diferente do sensor visual).
- CLAHE Multispectral: Equalização adaptativa local com ClipLimit=2.0 e grade 8x8 para manter assinaturas térmicas sem saturação.
- Normalização de Tensores: Estandarização ImageNet por canal.
- Pró: Processa todo o campo de visão em uma única inferência direta.
- Contra: Objetos distantes ficam comprimidos em 3 a 5 pixels.

Blend Cena Completa (DEF-RGBTCC)




Sobreposição Multimodal Panorâmica

PIPELINE 01: RECORTES LOCAIS (448x448)

- Preservação de Escala Nativa 1:1: Extração direta de janelas de atenção sem downsampling espacial, mantendo a geometria exata dos pedestres.
- Co-Registro Sincronizado: Recorte simultâneo em RGB e térmico.
- Adequação a Redes Densas: Adapta tensores locais para compatibilidade com strides convolucionais e tamanhos de patch 16x16 / 32x32.
- Pró: Altíssima fidelidade morfológica em alvos individuais.
- Contra: Requer varredura por janela deslizante para cobrir a cena.

Blend Recorte Local (small-images)



Resolução Nativa sem Degradação de Pixel

Matriz Geral de Desempenho e Validação Quantitativa

Comparação direta de contagem, acurácia relativa (NAE), erro quadrático (MSE) e telemetria

Subprojeto	Arquitetura Neural	Cenário Operacional	GT Real	Estimativa	Erro Abs.	NAE (%)	MSE 2D	Latência / FPS
DEF-RGBTCC	DualStreamNet (VGG19)	Cena Completa (1280x1024)	532	90 pess. (Int.)	-442	83.1%	0.000004	6.1 ms (165 FPS)
liuzywen-RGBTCC	PVTv2 (Vision Transf.)	Cena Completa (1280x1024)	532	82 pess. (Picos)	-450	84.6%	0.493947	16.4 ms (60.9 FPS)
DEF-small	DualStreamNet (VGG19)	Recorte Calçada (448x448)	9	26 pess. (Picos)	+17	188.9%	0.000001	240.0 ms (4.2 FPS)
liuzywen-small	PVTv2 (Vision Transf.)	Recorte Calçada (448x448)	9	13 pess. (Picos)	+4	44.4%	0.000003	18.5 ms (54.0 FPS)

LÍDER DE VELOCIDADE (GPU)

DEF-RGBTCC (165 FPS)

Latência de apenas 6.1 ms

LÍDER DE PRECISÃO NO RECORTE

liuzywen-small (NAE 44%)

Apenas +4 de erro em relação ao GT


REJEIÇÃO DE RUÍDO TÉRMICO

Vision Transformer


Zero picos em áreas vazias de controle

Contraste espacial entre a resposta contínua da CNN e a atenção seletiva do Vision Transformer

1. DEF-RGBTCC (CNN): Predição vs Ground Truth vs Resíduo Espacial (MSE: 0.000004)




2. liuzywen-RGBTCC (ViT): Predição vs Ground Truth vs Resíduo Espacial (MSE: 0.493947)




Por que redes treinadas em multidões extremas exigem pós-processamento para poucas pessoas?

Correlação nos 4 Cenários: CNN DEF



Offset aditivo causado por ruído térmico

Correlação nos 4 Cenários: Transformer Liuzzywen



Excelente proporcionalidade e zero ruído no vazio

Recomendações técnicas para implantação em sistemas de monitoramento em tempo real

QUANDO UTILIZAR DEF-RGBTCC (CNN)

- Aplicações de Ultra Alta Velocidade: Com latência de 6.1 ms (165 FPS), é a melhor escolha para dispositivos embarcados (NVIDIA Jetson / drones).
- Aglomerações Densas Homogêneas: Excelente resposta quando a multidão está concentrada em praças, shows ou entradas de eventos.
- Requisito Operacional: Aplicar mosaico (patching) se a câmera estiver muito distante para resolver a perda de pedestres de 3 pixels.

QUANDO UTILIZAR LIUZYWEN-RGBTCC (ViT)

- Vigilância Perimetral Crítica: Onde falsos alarmes são proibitivos e a presença de 1 a 10 indivíduos precisa de alta confiabilidade.
- Rejeição Natural de Luminárias: A atenção cruzada descarta postes de luz e asfalto quente sem necessidade de máscaras manuais.
- Throughput Adequado: 54 a 60 FPS atendem plenamente streams de CFTV.

ARQUITETURA HÍBRIDA RECOMENDADA EM PRODUÇÃO

1. Pipeline em Cascata Adaptativa: Empregar DEF-RGBTCC como classificador rápido de cena completa (6 ms). Se a energia contínua for baixa (< 50 pessoas), acionar janelas de atenção locais com o Vision Transformer para contagem discreta por picos, aproveitando a imunidade a ruído do PVTv2.
2. Calibração Geometria Obrigatória: A pré-transformação (Notebook 01) demonstrou ser insubstituível — sem a homografia multimodal, o desalinhamento óptico-térmico degrada a contagem em mais de 60%.
3. Padronização de Ground Truth: O alinhamento das anotações em 532 pessoas reais consolida uma base sólida para auditoria e futuros re-treinamentos com Loss balanceada de densidade.